

基于生存分析与 Uplift 建模的游戏付费策略设计

摘要

本文面向策略类游戏“代号 K”新服首月运营场景，围绕“留存约束下的营收优化”构建由留存预测、付费机理识别、玩家分群与动态投放构成的一体化模型。针对问题 1，基于前 3 天行为特征建立 Kaplan-Meier、Nelson-Aalen 与 Cox 比例风险模型，在严格避免信息泄漏的前提下刻画玩家生命周期，得到次日、7 日、14 日和 30 日留存率分别为 42.30%、22.95%、16.10% 和 7.05%，Cox 模型 C-index 为 0.826。针对问题 2，利用全周期资源与付费特征识别出 4-6 级为关键瓶颈区间，钻石存量 566 为 7 日流失风险超过 50% 的阈值；两阶段 Hurdle 模型表明，付费概率主要受行为广度驱动，付费金额主要受钻石存量与资源消耗强度影响。针对问题 3，提出“全周期画像-Day1-3 早期识别-Uplift 四象限干预-蒙特卡洛验证”的可部署框架：在 K=5 玩家分群基础上，为 10,000 名新服玩家设计分时、分群、分价礼包策略。模拟结果表明，优化方案在满足 30 日留存率 11.4% 且不低于 10% 约束的条件下，可实现 67,715 元期望营收，较无干预基线提升 2.8 倍，达到 70,000 元目标的概率为 24.1%。研究表明，面向零氪休闲党、零氪浅层党与中氪战力党的差异化首购转化与状态触发式补给，是兼顾留存与收入的关键。本文方法适用于缺乏 A/B 测试条件下的 SLG 运营优化，但需求曲线参数、Uplift 象限比例及实时资源缺口刻画仍需通过上线实验与新增埋点进一步校准。

关键词：生存分析；Cox 比例风险模型；两阶段 Hurdle 模型；玩家分群；Uplift 建模；蒙特卡洛模拟

一、 问题重述

策略类游戏”代号 K”即将开启新服运营，运营方提供了 2000 名训练用户与 1000 名测试用户的真实行为数据（含资源变更与行为事件两类记录），要求在留存与付费之间寻求最优平衡。本文依次解决以下四个递进问题：

问题 1：基于前 3 天行为数据建立流失预测模型，计算各级留存率并识别关键流失节点。

问题 2：量化资源消耗、成长速度与付费行为之间的关联，识别影响付费的关键因子。

问题 3：基于数据规律将玩家分层，为 10,000 名新服玩家设计差异化付费礼包策略，在留存率 $\geq 10\%$ 约束下最大化首月营收。

问题 4：基于建模发现，提出优先采集的数据类型，设计策略闭环修正框架。本文整体建模流程如图1所示。




图 1：整体建模流程图

二、 模型假设

为简化问题并确保模型的可行性，本文作出以下基本假设：

1. **分布一致性假设**：训练集 2000 名玩家的行为分布与新服 10,000 名玩家的行为分布一致，可基于训练集统计规律进行策略设计与验证。
2. **流失定义假设**：玩家连续 2 天无任何记录（资源变更与行为事件均无），则判定为该玩家已流失，流失日期为最后一条记录的日期。
3. **封闭系统假设**：玩家付费行为仅受游戏内因素（资源缺口、等级停滞、社交压力等）影响，忽略外部宏观经济因素和竞争对手游戏的影响。
4. **无重大事件假设**：30 天观察期内，游戏未发生重大版本更新、服务器故障或特殊运营活动等外部干扰。
5. **玩家独立性假设**：各玩家的行为相互独立，玩家之间的互动（如联盟协作）通过联盟参与特征间接反映，不直接建模玩家间依赖关系。
6. **付费瞬时性假设**：每次付费行为在触发条件满足时瞬间完成，不考虑玩家犹豫、支付失败等延迟因素。

三、符号说明

本文使用的主要符号及其含义见表1。

表 1: 主要符号说明

符号	含义
$S(t)$	t 时刻的生存函数（留存率）
$h(t)$	t 时刻的风险函数
$h_0(t)$	Cox 模型的基准风险函数
R_1, R_7, R_{30}	次日、7 日、30 日留存率
β_k	Cox 回归中第 k 个协变量的系数
X_k	Cox 回归中第 k 个特征变量
$\hat{y}$	XGBoost 模型对总付费金额的预测值
N_c	聚类 c 中的用户数量
r_c	聚类 c 的留存率
ARPU	每用户平均收入
$\hat{S}(t)$	Kaplan-Meier 生存函数估计量
d_i	t_i 时刻流失的用户数
n_i	t_i 时刻处于风险集中的用户数

本文涉及的模型相关术语及其英文对照见表2。

表 2: 核心术语中英文对照

中文	英文	缩写
生存分析	Survival Analysis	SA
Kaplan-Meier 估计	Kaplan-Meier Estimator	KM
Cox 比例风险模型	Cox Proportional Hazards Model	Cox PH
对数秩检验	Log-Rank Test	—
K 均值聚类	K-Means Clustering	K-Means
轮廓系数	Silhouette Score	—
多目标优化	Multi-Objective Optimization	MOO
蒙特卡洛模拟	Monte Carlo Simulation	MC
XGBoost 回归	Extreme Gradient Boosting	XGB
SHAP 解释	SHapley Additive exPlanations	SHAP

四、 玩家留存规律与流失预测模型

4.1 数据预处理与特征工程

原始数据由两类文件组成：pickdata1 和 pickdata2。由于数据量庞大，采用分块读取策略进行处理。

特征窗口约束。问题 1 要求基于前 3 天行为预测 30 天留存，因此严格限定仅使用第 1–3 天的数据。Day1 定义为玩家注册日期（register_time），若缺失则以首次 pickdata2 记录日期替代。提取的 14 个前 3 天特征包括：登录天数（days_logged_d3）、第 3 天等级（level_d3）、等级变化（level_change_d3）、日均在线时长（avg_duration_d3）、各类资源消耗量（food/wood/stone/diamond/coins_reduce_d3）、第 3 天钻石余额（diamond_d3）与金币余额（gold_d3）、是否首充（is_pay_d3，由 first_pay_time ≤ Day3 判定）、是否入盟（is_league_d3）及事件类型数（n_event_types_d3）。**绝对排除**以下全周期变量以避免未来信息泄漏：lifecycle_days、level_end、total_pay、vip_level_max、total_records、diamond_median。

4.2 Kaplan-Meier 留存率分析

4.2.1 模型建立

Kaplan-Meier (KM) 估计量 [1] 是一种非参数方法，用于估计生存函数 $S(t)$ ——即玩家在注册后第 t 天仍然活跃的概率。为全篇统一口径，定义玩家 i 的流失指标基于活跃跨度（lifecycle_days）：

$$T_i = \min(\text{lifecycle_days}_i, 30), \quad \delta_i = \mathbb{I}(\text{lifecycle_days}_i < 30) \quad (1)$$

即若玩家首末活跃跨度不足 30 天则判定为流失事件（ $\delta_i = 1$ ），否则在第 30 天右删失（ $\delta_i = 0$ ）[2]。KM 估计量为：

$$\hat{S}(t) = \prod_{i:t_i \leq t} \left(1 - \frac{d_i}{n_i}\right) \quad (2)$$

其中 d_i 为 t_i 时刻流失的玩家数， n_i 为 t_i 时刻仍在风险集中的玩家数。该估计量允许数据存在右删失。

4.2.2 结果分析

KM 留存曲线如图2所示。计算得到各级留存率如下：

- 次日留存率 (R_1): **42.30%**
- 7 日留存率 (R_7): **22.95%**
- 14 日留存率 (R_{14}): **16.10%**
- 30 日留存率 (R_{30}): **7.05%**

中位生存时间仅为 **1 天**，表明超过半数的玩家在注册后 24 小时内流失，该游戏面临严重的早期留存危机。30 日留存率 7.05% 与问题 3 基线留存率一致，全篇标签口径统一。




图 2: Kaplan-Meier 玩家留存曲线

4.3 流失高峰识别

4.3.1 模型建立

为识别流失的关键时间节点，采用 Nelson-Aalen 估计量 [3] 计算累积风险函数 $H(t)$ ，进而通过差分得到风险函数 $h(t)$ 的估计：

$$h(t) = \frac{\text{在}t\text{时刻流失的玩家数}}{\text{在}t\text{时刻仍处于风险集中的玩家数}} \quad (3)$$

对原始风险函数进行 3 天滑动窗口平滑处理，识别 $h(t)$ 的局部极大值点作为流失高峰。

4.3.2 结果分析

风险函数图见图3。活跃跨度分布分析显示：

- 第 2 天是生命周期结束的最高峰，57.7% 的玩家活跃跨度仅为 1-2 天
- 第 3 天为次高峰，19.9% 的玩家活跃跨度止于 2-3 天
- 第 4-5 天活跃跨度终止率仍约 9-10%，此后衰减放缓

这一发现提示运营团队应将最核心的留存干预资源集中在注册后的前 48 小时内。




图 3: 玩家流失风险率随时间变化（红色填充，虚线标注峰值位置）

4.4 分段留存对比分析

为探究不同玩家群体的留存差异，将玩家按付费状态和联盟参与状态分别进行分层 KM 分析。结果如图4所示，对比极为显著：

- 付费玩家 7 日留存率 **68.0%** vs 非付费玩家 7 日留存率 **21.2%**（差距 3.2 倍）
- 入盟玩家 7 日留存率 **61.5%** vs 未入盟玩家 7 日留存率 **13.4%**（差距 4.6 倍）

Log-rank 检验结果表明两组差异均具有高度统计显著性 ($p < 0.001$)。这一发现具有重要的策略含义：引导新玩家尽早完成首充并加入联盟，是提升整体留存率的最有效杠杆。




图 4: 分段留存曲线对比：付费 vs 非付费（左），加联盟 vs 未加联盟（右）

4.5 Cox 比例风险流失预测模型

4.5.1 模型建立

为实现基于前 3 天行为数据的留存天数预测，采用 Cox 比例风险模型 [4]。该模型是半参数模型，不要求指定基准风险函数的具体形式，而是将各协变量的影响建模为对基准风险的乘积效应：

$$h(t | X) = h_0(t) \exp(\beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k) \quad (4)$$

其中 $h_0(t)$ 为基准风险函数， $X = (X_1, \dots, X_k)$ 为协变量向量， β_k 为回归系数。 $\exp(\beta_k) > 1$ 表示该特征增加流失风险（“风险因子”）， $\exp(\beta_k) < 1$ 表示该特征降低流失风险（“保护因子”）。

选取 14 个严格限定于前 3 天的特征：登录天数、第 3 天等级、等级变化、日均在线时长、各类资源消耗量、钻石/金币余额、是否首充、是否入盟及事件类型数。绝对排除全周期变量（lifecycle_days、level_end、total_pay 等），避免预测目标与特征共享未来信息。

4.5.2 模型训练与评估

将数据集按 7:3 分层划分为训练集和测试集。采用惩罚似然估计（penalizer=0.1）降低过拟合风险。模型评估指标：

- 一致性指数（C-index）：**0.826**
- 预测平均绝对误差（MAE）：**4.36 天**

比例风险假设诊断与模型对照。显示 2 个协变量存在时间效应递减（days_logged_d3, $p=0.0001$; n_event_types_d3, $p=0.014$ ），其余 12 个满足 PH 假设。Schoenfeld 残差图（图5）显示违背最严重的协变量残差随时间递减，说明其保护效应在早期最强。本文保留 Cox 模型——其 C-index=0.826 排序能力良好且系数解释性优于非参数替代。以随机生存森林（RSF）[5] 作对照：RSF 的 C-index=0.768，低于 Cox。在有限样本下 Cox 的半参数结构具有偏差-方差权衡优势，本文以 Cox 为主模型、RSF 为对照。




图 5: Schoenfeld 残差图: PH 假设违背最严重的协变量 (days_logged_d3)

4.5.3 特征重要性分析

图6展示了各特征的回归系数及其 95% 置信区间。主要发现:

- **最强保护因子** ($\exp(\beta) < 1$):
 - 事件类型数 (n_event_types_d3): $\beta = -0.43$, $p < 0.001$
前 3 天内参与的游戏活动种类越多, 流失风险越低——行为多样性是留存的最强信号
 - 钻石余额 (diamond_d3): $\beta = -0.18$, $p < 0.001$
第 3 天钻石存量高的玩家投入更深, 流失风险更低
 - 登录天数 (days_logged_d3): $\beta = -0.17$, $p < 0.001$
前 3 天每日登录的玩家具有显著更高的留存概率
- **风险因子**: 模型中唯一达到统计显著的风险因子为金币余额 (gold_d3, $\beta = +0.08$, $p = 0.01$), 提示前 3 天金币存量偏高可能意味着玩家尚未找到有效的资源消耗出口, 间接增加了流失风险。其余特征的风险效应均不显著, 模型的流失预测主要依靠保护因子的强度。




图 6: Cox 模型各特征对流失风险的影响

预测生存天数与实际生存天数的散点图见图7，模型在中等生存时长区间表现良好，对极端长寿用户存在一定的低估。




图 7: Cox 模型预测生存天数 vs 实际生存天数

五、资源消耗与付费行为关联分析

数据窗口与货币说明：问题 2 探究资源消耗、成长速度与付费行为的关联，题目未限定时间窗口，本节使用全周期数据。付费相关字段（total_pay）以美元标价（0.99 USD 对应标准 6 元首充档），全文统一按 1 USD $\approx$ 6 CNY 折算为人民币呈现。

5.1 资源消耗与等级增长的量化关系

为量化玩家每日资源消耗量与等级提升速度的关系，计算各玩家的日均资源消耗量：

$$\text{日均消耗}_r = \frac{\text{资源}r\text{的总消耗量}}{\text{生命周期天数}}, \quad r \in \{\text{粮食, 木材, 矿石, 金币, 钻石}\} \quad (5)$$

采用 Pearson 相关系数衡量各资源消耗与等级增长（level_growth）之间的线性关联强度（所有 $p < 0.001$ ）：

资源	粮食	木材	矿石	钻石（存量）	钻石（消耗）	金币
r	0.394	0.395	0.504	0.277	0.379	0.342

矿石消耗与等级增长的相关性最强（ $r = 0.504$ ），粮食和木材次之（ $r \approx 0.39$ ），金币（ $r = 0.342$ ）和钻石存量（ $r = 0.277$ ）最弱。这一梯度与游戏内资源定位一致：粮木矿是日常升级的必需品，消耗量随等级增长成比例增加；金币可购买缺失资源但非每日刚需；钻石作为稀缺加速货币，作用不在日常消耗而在突破瓶颈时刻。

图8进一步展示了各等级玩家的日均资源消耗与等级增长速度（采用日均增长率 = 等级总增长/生命周期天数，避免存活时间差异导致的伪相关）。两个发现：

1. **升级瓶颈明确存在。** 1-5 级玩家日均升级 1.37 级/天，10 级以上玩家仅 0.37 级/天，降幅达 73%。等级超过 8 后日均增速降至 0.7 级/天以下，中后期存在显著的免费资源产出卡点。

2. 资源消耗量随等级指数增长，但效率递减。10 级以上玩家的日均粮、木、矿消耗量分别是 5 级玩家的 18–34 倍，等级增长却仅为后者的 37%——大量资源投入未等比例转化为升级进度。




图 8: 各等级玩家日均资源消耗量（左）与等级增长速度（右）

5.2 等级停滞的瓶颈分析

5.2.1 卡点识别

定义等级停滞玩家为日均升级速度 < 0.1 级/天且存活 ≥ 7 天的用户。瓶颈集中在 4–6 级：1–3 级为新手教程阶段，该阶段未升级的玩家本质上是已流失（生命周期 < 3 天）而非遭遇资源瓶颈；7 级及以上仅占 8% 且停滞样本不足，故聚焦 4–6 级。

表 3: 等级瓶颈特征（4–6 级：停滞 vs 非停滞玩家）

对比维度	停滞玩家	非停滞玩家	比值	解读
钻石存量 (中位)	600	594	$\approx 1:1$	钻石非瓶颈因素
矿石消耗 (中位)	42.5 万	5.2 万	$8.2\times$	停滞者刷更多资源
活跃天数 (中位)	10 天	5 天	$2\times$	停滞者在线更久
金币持有率	57%	39%	—	停滞者更倾向囤积
金币均值 (持币者)	50.3 万	13.7 万	$3.7\times$	金币无法转化为升级

表3揭示了一个看似矛盾的格局：停滞玩家在线时间是正常玩家的 2 倍，矿石消耗是 8.2 倍，粮木消耗约 4.3 倍——并非投入不足，而是资源向升级的转化效率断崖式下降。更关键的是，停滞者的金币持有率（57%）和持币量（50 万）远超非停滞者（39%，14 万），但巨额金币并未帮他们突破瓶颈：金币是停滞后积累的堆积物，而非瓶颈的解决方案。

5.2.2 钻石与金币的差异化预测角色

控制等级后建立 Logistic 回归：

$$P(\text{停滞} | X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 \cdot \log(1 + \text{钻石}) + \beta_2 \cdot \log(1 + \text{金币}) + \beta_3 \cdot \text{等级})}} \quad (6)$$

$$\beta_{\text{钻石}} = -0.355 \quad (\text{保护因子})$$

$$\beta_{\text{金币}} = +0.157 \quad (\text{风险因子})$$

钻石存量与停滞概率负向关联，金币存量与停滞概率正向关联。需注意：Logistic 回归识别的是统计关联而非因果关系——钻石与停滞的关系可能受玩家投入度等第三因素共同影响。等级 4+ 偏相关分析提供了一致的佐证：金币与增长的相关性 ($r = -0.143$) 远弱于矿石 ($r = -0.462$) 和粮木 ($r \approx -0.427$)，支持“钻石是瓶颈打破者、金币是停滞伴随物”的区分。

5.3 钻石存量与流失风险

将“7 天内流失”作为二分类目标变量 ($\text{lifecycle_days} < 7$)，以对数化钻石中位数为预测变量建立 Logistic 回归：

$$P(\text{流失} \mid \text{钻石}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 \cdot \log(1 + \text{钻石}))}} \quad (7)$$

求解 $P(\text{流失} \mid \text{钻石}) = 0.5$ 获得风险阈值：

$$\text{钻石存量} < 566 \text{ 时, 7 天内流失概率超过 50\%}$$

图9展示了钻石存量分布与流失概率曲线。




图 9: 钻石存量分布：留存 vs 流失玩家（左）与流失概率曲线（右）

5.4 钻石枯竭玩家的最优挽回礼包

题目进一步要求判断钻石低于流失阈值时“补给什么礼包能最有效挽回”。首先对钻石枯竭玩家进行画像。

筛选钻石存量 < 566 的玩家，共 1,610 人（占全量 80.5%）。该群体 7 天流失率 87.6%（阈值以上仅 27.4%），平均生命周期 4.0 天（阈值以上 22.8 天），付费率仅 1.1%（阈值以上 14.6%），日均资源消耗量约为阈值以上玩家的 1%——钻石枯竭伴随着全面行为萎缩。

综合本节四项分析得出礼包推荐：

1. 钻石是停滞的保护性预测因子 ($\beta = -0.355$) ——补钻石直击留存瓶颈

2. 停滞玩家矿石消耗为非停滞者的 8.2 倍——玩家有刷资源的意愿，缺乏的是将资源转化为进度的钻石
3. 钻石枯竭玩家付费率仅 1.1%，定价须极低以降低首付门槛
4. 问题 3 的付费策略中，6 元首充礼包预期转化约 1,200 名新服玩家（ARPU 贡献 0.72 元），30 元资源补给包贡献 0.75 元

推荐两档钻石补给礼包：（a）**6 元首充钻石包**，面向钻石 < 566 的零氪玩家，以最低门槛完成首购转化并提供少量钻石；（b）**30 元资源补给包**，面向钻石枯竭但有付费意愿的玩家，提供钻石与基础资源组合。推送触发条件为：监测到玩家钻石存量 < 566 且当日未付费。

局限性声明。数据中不含 A/B 测试或推送实验记录，上述推荐基于关联分析的间接推断。礼包的真实挽回效果需通过线上随机对照实验验证。本分析的贡献在于将推荐限定在有数据支撑的范围内（钻石补给而非粮木矿补给），避免盲目猜测。

5.5 首次付费分析

75 名付费用户（占总体 3.8%）的首次付费行为特征如下：

- **首次付费时间：**数据中 `first_pay_time` 字段值均为缺失或无效，无法提取首次付费的日期分布。这可能是数据脱敏或采集链路不完整所致，建议在后续数据采集中补充（见问题 4）。
- **首付等级：**100% 的付费用户首次付费发生在 1 级（注册初期），表明首充引导在注册阶段效果最佳。
- **付费金额分布：**中位数约 6 元（即 0.99 美元首充档），75% 分位数约 12 元，呈现极度右偏。
- **付费金额与留存：**高付费组（ ≥ 100 元，约 600 元 +）平均生命周期 71.0 天，低付费组（ < 36 元）平均 26.8 天。但需注意**存活者偏差**：生命周期长的玩家有更多时间累积付费，因此正相关部分源于时间暴露差异。两者更可能是双向强化关系——初始付费增强留存，更长留存提供更多付费机会，而非简单的付费 $\rightarrow$ 留存单向因果关系。

图10展示了付费金额分布与不同付费水平下的留存时长。




图 10: 付费金额分布 (左) 与不同付费水平下的平均生命周期 (右)

5.6 两阶段 Hurdle 模型分析总付费关键因子

5.6.1 模型建立

题目要求建立回归模型分析影响”总付费金额”的关键因子。直接对全体玩家做回归面临零膨胀问题——96.2% 的玩家付费为 0，模型将被零值主导。针对这一数据结构，采用两阶段 Hurdle 模型 [6]：

1. **阶段 1 (参与方程)**：XGBoost 二分类 [7]，目标 $y_1 = \mathbb{I}(\text{total_pay} > 0)$ ，全量 2000 名玩家参与训练。设置 `scale_pos_weight = 25.4` 平衡正负类权重，分层抽样保持训练/测试集正类比例一致。
2. **阶段 2 (金额方程)**：Gamma GLM with log link，目标为 $\mathbb{E}[Y | Y > 0, X]$ ，仅在 75 名付费玩家上训练。模型假设 $Y | X \sim \text{Gamma}$ 且 $\mathbb{E}[Y | X] = \exp(X\beta)$ ，是处理正偏态连续因变量的标准形式。特征经 F 检验预筛选 (top-5) 并剔除共线性对 ($|r| > 0.9$) 后保留 3 个，StandardScaler 标准化后拟合。拟合优度报告 **deviance explained** (偏差解释率)——Gamma 分布下传统 R^2 无定义。

5.6.2 模型性能

阶段 1：AUC-ROC = 0.9315，模型具有良好的付费-非付费判别能力。付费类精确率与召回率均为 0.4091 ($F1 = 0.4091$)，在 3.8% 正类率的稀疏场景下合理。

阶段 2：全量 75 人拟合偏差解释率 0.822，测试集 RMSE = 1.27 (标准化空间)。以 53 个训练样本解释付费金额的个体差异是固有困难——付费金额受促销活动、玩家个人财务状况等大量未观测因素影响，阶段 2 的定位是识别有价值的特征方向，而非精确预测。

5.6.3 特征重要性分析

两阶段揭示了”是否付费”与”付多少”的不同驱动模式。图11展示阶段 1 SHAP[8] 特征重要性，图12展示阶段 2 Gamma GLM 显著系数。

阶段 1——谁更可能付费？ SHAP 排名前 5 的特征为：`n_event_types` (事件类型数)、`diamond_get` (钻石获取量)、`total_get` (总获取量)、`diamond_flow` (钻石净流量)、`re-`

source_intensity（资源消耗强度）。这组特征共同刻画了**参与广度**——活动参与种类越多、资源获取量越大，接触付费场景的机会越多，首购转化概率越高。

阶段 2——付费者中谁付得更多？ Gamma GLM 经预筛选和共线性过滤后保留 3 个特征，其中 2 个达到统计显著：

特征	$\exp(\beta)$	p 值	解读
diamond_median	2.86	0.006	钻石中位数每增 1 SD，期望付费 $\times 2.86$
total_reduce	3.36	0.018	总消耗每增 1 SD，期望付费 $\times 3.36$
diamond_get	0.39	0.187	未达统计显著

diamond_median 的显著正向效应（ $p = 0.006$ ）与钻石流失阈值和等级停滞分析高度一致。total_reduce 的显著性（ $p = 0.018$ ）反映了高消耗玩家为维持资源需求而进行更高额付费的行为模式。

5.6.4 不确定性量化

鉴于阶段 2 仅 53 个训练样本（全量 75 名付费者），点估计的统计稳定性需要量化。对关键指标进行 Bootstrap 重采样（1,000 次）：

指标	中位数	95% Bootstrap CI
钻石阈值	566	[497, 644]
阶段 1 AUC	0.932	[0.919, 0.991]
$\exp(\beta)_{\text{diamond_median}}$	1.991	[0.917, 4.031]

钻石阈值 CI 较紧（[497, 644]），阈值 566 的估计相对稳健。阶段 1 AUC 的 CI（[0.919, 0.991]）确认了付费概率判别能力的稳定性。阶段 2 系数的 CI 较宽——diamond_median 的 $\exp(\beta)$ 95% CI 跨 0.917 至 4.031——这是付费子样本稀疏（ $n = 75$ ）的必然结果。其余 GLM 特征的 CI 因样本量限制同样较宽，本文报告 Bootstrap 区间以坦诚刻画不确定性，而非仅报告单一显著水平下的点估计。

综合解读：两阶段给出了一个清晰的二分——**付费门槛由参与广度突破，付费深度由资源消费强度驱动**。对运营策略的直接启示：**提升首购转化应扩大玩家活动参与面，提升付费深度应聚焦高钻石存量、高资源消耗玩家的精细化运营**。关于 resource_intensity 需补充说明：该指标衡量的是**资源消费强度**（日均消耗量），而非严格意义上的“资源缺口”（需求与供给的差额）——数据中缺乏直接衡量资源缺口的字段（如当前升级所需资源量与持有量的差额），建议在问题 4 的数据采集中补充。




图 11: 阶段 1 XGBoost SHAP: 影响付费概率的关键因子




图 12: 阶段 2 Gamma GLM 系数: 影响付费金额的关键因子

六、新服首月付费策略设计与收益最大化

6.1 建模思路与三方案对比框架

问题 3 的目标是：基于前两问的数据规律，为新服 10,000 名玩家设计 30 天差异化付费礼包推送策略，在 30 日留存率 $\geq 10\%$ 的约束下最大化总营收（目标 70,000 元）。核心挑战在于从有机付费（无推送干预）推断干预条件下的购买概率。本文设计三组递进对比方案：

方案	定位	购买概率来源
基线	无任何推送，纯有机付费	历史聚类付费率
基准方案	基于历史模式的固定礼包策略	有机付费率 $\times$ 价格乘子
优化方案	Uplift 因果框架的增强策略	付费用户：增量叠加；零氪用户：四象限干预

三组对比的论证价值：基线 $\rightarrow$ 基准量化固定策略的增量，基准 $\rightarrow$ 优化量化 Uplift 框架的额外增益。

6.2 玩家聚类分析

6.2.1 聚类方法与命名规则

采用 K-Means 算法 [9] 对训练集 2,000 名玩家进行聚类。选取 11 个特征：days_active、life-cycle_days、level_end、level_growth_rate、is_paying、total_pay、is_in_league、vip_level_max、diamond_median、total_get、total_reduce。对偏态分布特征（total_pay、diamond_median 等）进行 $\log(1+x)$ 变换后，StandardScaler 标准化至均值 0、方差 1。

6.2.2 聚类数的选择

为确定最优聚类数 K ，对 $K = 2, 3, \dots, 8$ 分别运行 K-Means 并比较四项指标：轮廓系数（Silhouette）[10]、Calinski-Harabasz 指数（CH）、Davies-Bouldin 指数（DB）及最小簇占比。结果如下：

K	Silhouette	CH Index	DB Index	最小簇占比
2	0.451	861.8	1.232	23.5%
3	0.449	951.4	1.021	7.2%
4	0.478	1039.8	1.004	4.0%
5	0.488	1093.9	0.928	1.1%
6	0.490	1085.6	0.839	0.1%
7	0.478	1088.6	0.904	0.1%
8	0.486	1147.1	0.837	0.1%

$K = 5, 6$ 的轮廓系数较高，但 $K = 6$ 的最小簇仅 0.1%，统计上不可靠。本文以最小簇占比 $\geq 1\%$ 为稳定性约束，选择满足约束下轮廓系数最大的 $K = 5$ （Silhouette=0.488）。K-Means 的肘部法则曲线与轮廓系数曲线见图13。




图 13: K-Means 肘部法则（左）与轮廓系数曲线（右，最佳 $K = 5$ ）

聚类命名基于中心排序规则，按平均付费金额和生命周期两个维度将 5 个聚类划分为五种策略类型：

命名	付费条件	排序条件	典型特征
高氪核心党	有付费	平均付费金额最高	高付费、长生命周期、100% 留存
中氪战力党	有付费	平均付费金额次高	中等付费、战力导向
零氪休闲党	零付费	生命周期较长	长期活跃但未付费
零氪浅层党	零付费	生命周期中等	短期活跃后流失
零氪流失党	零付费	生命周期极短	注册即离

6.2.3 聚类结果

表 4: 五类玩家聚类特征 ($K = 5$)

ID	命名	占比	付费率	平均付费 (元)	生命周期 (天)	30 日留存
C0	高氪核心党	1.1%	66.7%	48.08	62.3	100%
C1	零氪浅层党	50.6%	0.0%	0.00	3.5	1.2%
C2	零氪休闲党	19.2%	0.0%	0.00	22.2	26.1%
C3	中氪战力党	3.1%	100%	2.09	21.3	24.6%
C4	零氪流失党	26.2%	0.0%	0.00	1.4	0.4%

核心发现：约 96% 的玩家（C1/C2/C4）30 天内从未付费。零氪休闲党、零氪浅层党与零氪流失党构成三级零氪分层，为四象限策略提供了差异化干预空间。K=5 相比 K=4 多分离出一个高氪子群和一个零氪浅层子群。3D 聚类可视化结果见图14。




图 14: 3D 聚类可视化：生命周期-对数总付费-最高等级

6.3 早期可部署分群：教师-学生架构

上述 K-Means 聚类使用了 30 天终态特征 (level_end、total_pay 等)，在新服玩家刚注册时尚无法获取。为使聚类分群在运营中可实时部署，构建教师-学生两阶段架构：

1. **教师模型：**全周期 K-Means ($K = 5$) 对历史玩家进行聚类，生成高质量的分群标签。
2. **学生模型：**XGBoost 多分类器，仅使用 14 个 Day1-3 特征预测全周期聚类标签。

学生模型在 5 折分层交叉验证中取得 **92.2%** 的准确率 ($\pm 0.8\%$)，各类 F1 均在 0.92 以上。Day1-3 预测的最强特征为：第 3 天等级 (重要性 0.424)、是否首充 (0.172)、是否入盟 (0.158)、粮食消耗量 (0.084) 及事件类型数 (0.044)。这一架构使新服玩家在注册第 3 天即可获得策略分类——虽准确率低于全周期聚类，但在时效性与信息量之间取得了合理的权衡。

6.4 基准方案：历史分布增强策略

基准方案基于可观测的历史数据，假设推送不改变玩家基本付费意愿——购买概率 $P = \text{有机付费率} \times \text{价格乘子}$ 。

表 5: 基准方案礼包体系（7 档）

礼包	价格 (元)	购买概率乘子	留存加成
首充礼包	6	1.00	+2%
新手补给	12	0.50	+2%
资源补给包	30	0.40	+3%
成长加速包	68	0.15	+4%
战力突破包	128	0.05	+5%
至尊大礼包	328	0.01	+6%
传说大礼包	648	0.003	+7%

所有聚类使用统一的价格乘子。零氪集群（~96%）的有机付费率为 0，因此 $P_{\text{push}} \approx 0$ ，基准方案的策略增量主要来自 ~4% 的付费集群。该方案的优势在于所有参数均可从历史数据直接观测，方法论透明、可复现。

6.5 优化方案：Uplift 因果框架的混合策略

6.5.1 需求曲线与干预弹性

优化方案的核心是为零氪玩家创造购买概率。本文采用指数需求函数 $f_c(p) = \alpha_c \cdot e^{-\beta p}$ ，其中 α_c 为聚类 c 的基准购买意愿， β 为价格敏感系数。 β 的基准估计为 $\hat{\beta} = 1/\mathbb{E}[\text{total_pay}] = 0.066$ （指数分布 MLE），但该估计仅反映无推送条件下已成交玩家的价格分布，存在三个局限：仅有成交数据而无拒绝数据；共享 β 忽略聚类间价格敏感度差异；均值被极端值拉偏（64% 付费者 <1 元，1 人 455 元）。因此， $\beta = 0.020$ 的取值参照了行业基准 [11] 对推送引导下价格敏感度的校准——推送降低了玩家的信息搜索成本，价格敏感度低于被动探索状态。后续通过敏感性分析验证结论对 β 和 λ_c 的稳健性。

6.5.2 付费用户：全量增量叠加

对于有付费历史的集群（中氪战力党、高氪核心党），推送在基准方案概率基础上叠加增量：

$$P_{\text{push}}(c, p) = \min(0.99, P_{\text{conservative}}(c, p) \times (1 + \delta_c)) \quad (8)$$

其中中氪战力党 $\delta = 0.85$ ，高氪核心党 $\delta = 0.80$ 。依据：随机对照试验 [12] 证明有付费历史的玩家对推送呈正向响应。

6.5.3 零氪用户：四象限 Uplift 框架

对于零氪集群，引入 Uplift 建模中的四象限分类 [11]：

象限	不推不买	推了才买	策略
Persuadable（可转化者）	是	是	精准推送——ROI 全部来自他们
Sure Thing（自然购买者）	否	否	不推送——零付费率下不存在
Sleeping Dog（逆反者）	是	否	抑制推送——推送导致反感
Lost Cause（无法触及者）	是	是（但生命周期过短）	仅推免费挽留包

各聚类的四象限比例假设（见表6）基于 SLG 行业首充转化率基准校准，并通过敏感性分析验证稳健性。

表 6: 各聚类的四象限分布假设

聚类	Persuadable	Sleeping Dog	Lost Cause	Sure Thing
高氪核心党	50%	0%	0%	50%
中氪战力党	60%	10%	0%	30%
零氪休闲党	70%	5%	25%	0%
零氪浅层党	50%	5%	45%	0%
零氪流失党	30%	5%	65%	0%

Persuadable 的推送。购买概率 $P_{\text{push}} = \lambda_c \cdot e^{-\beta p}$ ，其中 λ_c 为聚类特异性的首购转化基线（零氪休闲党 0.30，零氪浅层党/流失党 0.10）， $\beta = 0.020$ （经价格敏感度校准）。Persuadable 用户按价格升序遍历礼包，购买后自动跳过所有更低价格礼包（自适应推送）；生命周期 <3 天时跳过 >30 元的高价礼包（状态触发）。

Lost Cause 的免费挽留。对 Lost Cause 用户推送价格为 0 的免费挽留包，通过留存加成（+8%）延长其生命周期，创造后续有机付费和付费包转化窗口。

Sleeping Dog 的抑制。对 5% 的逆反型用户完全抑制推送——Uplift 模型不仅优化”推给谁”，也优化”不推给谁”。

6.5.4 推送日程与状态触发

优化方案在固定日程推送（Day 1/3/7/10/14/21/28）基础上增加状态检测：

- 生命周期 <3 天 → 跳过 >30 元的礼包
- 高氪核心党 → 跳过 <30 元的礼包（低价包对高付费用户具有侮辱性）
- 已购买 ≥ 128 元包 → 跳过 <68 元的礼包（自适应升档）
- 钻石存量 <566 → 推荐资源补给包（整合问题 2 的流失阈值发现）

6.6 蒙特卡洛模拟验证与目标可达性

6.6.1 模拟设计

对三组策略分别进行 $N = 5,000$ 次独立蒙特卡洛模拟 [13]。每次模拟生成 10,000 名玩家：按聚类占比抽样，生命周期从各聚类的对数正态分布抽取，有机付费金额从指数分布抽取。策略付费按各方案规则决定，留存判定为：

$$P(\text{留存}) = \text{retention_base} + \sum \text{ret_boost} - \text{ret_penalty} \quad (9)$$

其中 ret_boost 来自每次成功购买 (+2% 至 +8%)， ret_penalty 包括推送频次惩罚 ($0.003 \times \text{推送次数}$) 和价格压力惩罚 ($0.001 \times \text{均价}/100$)。

6.6.2 模拟结果

表 7: 三方案蒙特卡洛模拟结果

指标	基线（无干预）	基准方案	优化方案
期望总营收 (元)	24,058	44,735	67,715
期望 30 日留存率	7.0%	7.2%	11.4%
$P(\text{营收} \geq 70,000)$	0%	0.0%	24.1%

优化方案实现营收 67,715 元 ($2.8 \times$ 有机基线, 较基准方案 +51.4%), 留存率 11.4% 满足 $\geq 10\%$ 约束。三参数敏感性检验 (Persuadable 比例 $\pm 20\%$) 表明: 悲观情景营收 63,269 元、留存 11.5%; 乐观情景营收 69,326 元、留存 11.2%。在乐观情景下营收接近 70,000 元目标, 基准情景 $P(\text{营收} \geq 70,000) = 24.1\%$ 。关于首购转化基线 λ_c 和增量乘数 δ_c 的设定: 参照行业基准校准, 且本文通过敏感性分析验证了结论对该假设的稳健性。

表 8: 优化方案各礼包预期贡献 (10,000 玩家, 30 天)

礼包	价格 (元)	推送时机	目标人群	预期购买 (人)	预期收入 (元)
免费挽留包	0	每日	Lost Cause(零氪)	~2,800	0
首充礼包	6	Day 1	Persuadable(零氪/中氪)	~1,600	~9,600
新手补给	12	Day 3	Persuadable(零氪)	~600	~7,200
资源补给包	30	Day 7/钻石 <566	中氪战力党	~400	~12,000
成长加速包	68	Day 10	中氪战力党	~150	~10,200
战力突破包	128	Day 14	中氪/高氪	~70	~8,960
至尊大礼包	328	Day 21	高氪核心党	~8	~2,624
传说大礼包	648	Day 28	高氪核心党	~2	~1,296
合计				~5,600	~52,000

注: 预期购买人数为 MC 模拟均值取整。表内为各礼包预期销售额 (含对有机付费的部分替代)。优化方案总营收 67,715 元 (含有机付费 24,058 元)。




图 15: 三方案蒙特卡洛模拟分布：总营收（左）与 30 日留存率（右）




图 16: 蒙特卡洛模拟收敛性验证：5000 次迭代下营收均值与标准差均已稳定

6.7 本节小结

本节通过 K-Means 聚类 ($K = 5$, 经多指标比较选定) 将玩家分群, 教师-学生架构 (CV 92.2%) 实现 Day3 实时部署。5,000 次 MC 模拟验证优化方案: 67,715 元营收、11.4% 留存率, $P(\geq 70,000) = 24.1\%$ 。敏感性区间 63,269–69,326 元, 留存 11% 以上。较基准方案营收 +51.4%、留存 +4.2pp, 验证了 Uplift 框架在双目标优化中的方法论价值。

七、数据采集建议与策略闭环

基于前三问的建模分析发现, 建议游戏服务器优先采集以下两类新埋点数据。

7.1 建议一：社交行为数据

建议采集字段：好友互动频次（好友列表、私聊次数、赠礼次数）、联盟聊天消息数及活跃时段、组队（集结/集结参与）次数与成功率、被攻击/被侦查记录。

理由：问题 1 的分段 KM 分析表明前 3 天加联盟用户的 7 日留存率 (28.0%) 是未加联盟用户 (1.2%) 的 23 倍——联盟是留存最显著的单变量预测因子。Cox 多变量回归进一步确

认了联盟参与的保护效应 ($\exp(\beta) = 0.90, p < 0.001$)，在控制了行为多样性、钻石存量等因素后仍具统计显著性。然而，当前仅有布尔型“是否加联盟”标签，无法量化社交深度。精确的社交行为数据可将“浅社交”（仅加入联盟但不活跃）与“深社交”（频繁互动、组队、聊天）用户区分开来，二者的留存和付费行为可能存在数量级差异。

策略闭环修正：

- 社交深度高 + 进度压力低 → 低频推送 (≤ 1 次/周)，减少打扰
- 社交深度高 + 进度压力高 → 中频推送 (2 次/周)，推送联盟专属礼包
- 社交深度低 + 进度压力低 → 中频推送，引导加入联盟
- 社交深度低 + 进度压力高 → 精准触发式推送，低价社交激励礼包

7.2 建议二：实时战力/进度数据

建议采集字段：PVP/GVG 战斗胜负记录及战力变化、各建筑等级及升级剩余时间、科技树研究进度、主线/支线任务完成进度、英雄收集数量与星级分布。

理由：问题 2 的资源-等级弹性分析显示资源消耗与等级增长相关性显著 ($r = 0.39-0.50$)，但当前数据仅有资源变化记录，缺少“进度目标”信息。玩家是否有未完成的升级/研究/任务是判断资源缺口的关键——资源缺口率应定义为“ $(\text{所需资源} - \text{持有资源}) / \text{所需资源}$ ”，仅凭消耗量无法精确计算。PVP 胜负记录则是判断“进度焦虑”的核心信号，连续 N 次 PVP 失败是触发“战力突破礼包”的最佳时机。

策略闭环修正：

- 建立“进度压力指数”：综合 PVP 胜率、建筑排队时间、资源缺口率三维指标
- 资源缺口率 $> 50\%$ → 推送低价补给包 (6 元，降低决策门槛)
- 资源缺口率 $> 80\%$ 且 PVP 连败 ≥ 3 次 → 推送高价突破包 (68-128 元)
- 升级受阻（建筑等待时间 $>$ 阈值）→ 推送加速道具包

7.3 AB 测试验证框架

新服上线后，建议采用 AB 测试验证增强策略的有效性：

- **对照组：**仅使用问题 3 的基准方案（固定礼包策略）
- **实验组：**使用社交 + 进度维度的增强动态策略
- **评估指标：**对比两组 30 日 ARPU、留存率、各聚类付费转化率
- **迭代机制：**每周根据数据更新策略参数，持续优化

八、模型评价与推广

8.1 优点

1. **数据完整性保障**：问题 1 严格使用仅前 3 天特征，消除信息泄漏；问题 2 使用全周期数据做关联分析；问题 3 综合前两问结论设计策略。三问数据窗口分工明确、逻辑递进。
2. **因果推断框架**：问题 3 引入 Uplift 四象限分类，区分推送增量效应与有机购买，避免传统响应模型的效率损失。
3. **方法完备性**：Cox PH 诊断与 RSF 对照验证模型选择合理性；Bootstrap 量化关键指标不确定性；K=2-8 多指标比较替代硬编码聚类数；教师-学生架构（CV 92.2%）实现 Day3 实时分群部署。三方案递进对比结合 5,000 次 MC 模拟，优化方案 67,715 元营收（ $2.8\times$ 基线），留存率 11.4%。
4. **实践可操作**：策略方案包含推送时机、状态触发条件、四象限分类、目标人群与定价，可直接转化为运营配置。

8.2 不足与改进

1. **策略参数需 A/B 测试标定**：需求曲线与四象限比例基于历史数据推断和行业基准，通过敏感性分析验证了结论稳健性。若获得随机对照试验数据可进一步无偏估计。
2. **付费子样本有限**：训练数据仅 75 名付费玩家（3.75%），源自题目给定数据。Bootstrap 方法已用于量化不确定性，数据积累后精度将进一步提升。
3. **分布迁移与扩展性**：MC 模拟假设新老服同分布，建议持续收集新服数据更新模型。K=5 经多指标比较选出，聚类选择框架具有方法论可迁移性。

8.3 推广价值

本文方法体系具有较强的通用性：

- **SLG/卡牌/RPG 类游戏 [14]**：用户生命周期特征相似，聚类 + Uplift 策略优化框架可直接迁移；生存分析框架适用于订阅制/会员制产品的用户流失分析。
- **无 A/B 测试条件下的策略设计**：本文展示的”基准方案 + Uplift 优化 + 敏感性分析”范式，为无随机对照数据时的策略优化提供了可复用的方法论。

参考文献

- [1] Kaplan E L, Meier P. Nonparametric estimation from incomplete observations[J]. *Journal of the American Statistical Association*, 1958, 53(282): 457-481.
- [2] Kleinbaum D G, Klein M. *Survival Analysis: A Self-Learning Text*[M]. 3rd ed. New York: Springer, 2012: 1-700.

- [3] Aalen O. Nonparametric inference for a family of counting processes[J]. *Annals of Statistics*, 1978, 6(4): 701–726.
- [4] Cox D R. Regression models and life-tables[J]. *Journal of the Royal Statistical Society: Series B (Methodological)*, 1972, 34(2): 187–202.
- [5] Ishwaran H, Kogalur U B, Blackstone E H, et al. Random survival forests[J]. *Annals of Applied Statistics*, 2008, 2(3): 841–860.
- [6] Belotti F, Deb P, Manning W G, et al. twopm: Two-part models[J]. *The Stata Journal*, 2015, 15(1): 3–20.
- [7] Chen T, Guestrin C. XGBoost: A scalable tree boosting system[C]. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, 2016: 785–794.
- [8] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]. *Advances in Neural Information Processing Systems (NeurIPS)*, Long Beach, 2017: 4765–4774.
- [9] MacQueen J. Some methods for classification and analysis of multivariate observations[C]. *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, Berkeley, 1967, 1(14): 281–297.
- [10] Rousseeuw P J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis[J]. *Journal of Computational and Applied Mathematics*, 1987, 20: 53–65.
- [11] Wei Z, Liu Y, Zhang H, et al. Multi-treatment multi-task uplift modeling for enhancing user growth[J/OL]. *arXiv preprint arXiv:2408.12803*, 2024. <https://arxiv.org/abs/2408.12803>.
- [12] Ascarza E, Netzer O, Runge J. Personalized game design for improved user retention and monetization in freemium mobile games[J]. *International Journal of Research in Marketing*, 2025, 42(4): 975–995.
- [13] Hammersley J M, Handscomb D C. *Monte Carlo Methods*[M]. London: Methuen, 1964: 1–178.
- [14] Pape P, Hekimoğlu M, Wierenga B. Personalized content, engagement, and monetization in a mobile puzzle game[J]. *International Journal of Research in Marketing*, 2024, 41(3): 528–546.

A 附录

1.1 附录 A：特征工程流程与字段映射

原始数据由 pickdata1（资源变更记录，33 字段）和 pickdata2（用户行为事件记录，52 字段）组成。表9列出了关键字段与实际数据来源的映射关系。

表 9: 关键字段映射

题目需求	实际来源	提取方式
玩家基础信息	pickdata2: register_time, total_pay, current_level	按用户聚合取最新值
登录活跃	pickdata2: dt, account_id	按用户 + 日期聚合
付费信息	pickdata2: total_pay, first_pay_time	取用户级 max 值
资源消耗	pickdata1: resource_name, change_type, change_num	筛选 reduce, 按资源名 + 用户

特征工程流程如下：

1. 分块读取 pickdata1（1,931,166 行）和 pickdata2（4,158,533 行）
2. 按 account_id 分组聚合，计算各用户的 39 个特征
3. 输出 player_features.csv（2000 行 × 39 列），供后续各问题使用

1.2 附录 B：策略方案完整表

优化方案的完整 8 档礼包策略方案见表10。

表 10: 优化方案策略完整表（8 档礼包）

礼包名称	定价 (元)	推送时机	触发条件	目标人群
免费挽留包	0	Day 1-30	Lost Cause 象限	零氪浅层党、零氪流失党
首充礼包	6	Day 1	Persuadable, 注册首日	零氪休闲党、零氪浅层党、中氪战力党
新手补给	12	Day 3	Persuadable, 活跃 ≥2 天未付费	零氪休闲党、零氪浅层党
资源补给包	30	Day 7	Persuadable, 活跃 ≥5 天或钻石 <566	中氪战力党
成长加速包	68	Day 10	Persuadable, 连续 2 天资源缺口 >30%	中氪战力党
战力突破包	128	Day 14	Persuadable, 等级停滞 ≥3 天	中氪战力党、高氪核心党
至尊大礼包	328	Day 21	Persuadable 高氪, 等级 ≥10 且已购 ≥68 元包	高氪核心党
传说大礼包	648	Day 28	Persuadable 高氪, 已购 328 元包	高氪核心党

注：零氪用户四象限分类（零氪休闲党 Persuadable 70%、Lost Cause 25%；零氪浅层党 Persuadable 50%、Lost Cause 45%；零氪流失党 Persuadable 30%、Lost Cause 65%；Sleeping Dog 统一 5%），付费用户全量推送无象限区分。状态触发：生命周期 <3 天跳过 >30 元，高氪跳过 <30 元，已购 ≥128 元跳过 <68 元。

1.3 附录 C：蒙特卡洛模拟参数设置

表 11: 蒙特卡洛模拟关键参数

参数	设定值
模拟玩家总数 N	10,000
模拟重复次数	5,000
玩家聚类数 K	5
礼包数量	8（含免费挽留包）
三方案	基线 / 基准方案 / 优化方案
留存率目标约束	$\geq 10\%$
营收优化目标	max 总营收（目标 70,000 元）
随机种子	42

1.4 附录 D：资源缺口程度的定义说明

题目要求分析“资源缺口程度”对付费金额的影响。理想的资源缺口应定义为玩家当前升级/建造所需资源与持有资源之间的差额比率：

$$\text{资源缺口率} = \frac{\text{升级所需资源量} - \text{当前持有资源量}}{\text{升级所需资源量}} \quad (10)$$

该指标直接反映玩家为推进进度而付费的紧迫性——缺口率越高，付费动机越强。然而，现有数据仅包含资源变更记录（获取/消耗量），缺少两个关键字段：（1）各玩家当前升级/建造目标所需的资源量；（2）资源消耗的目的分类（升级消耗 vs 日常维护消耗）。因此无法精确计算上述缺口率。

本文在 Hurdle 模型阶段 1（SHAP 分析）和阶段 2（Gamma GLM）中以 `resource_intensity`（日均资源消耗量 = 总消耗量 / 生命周期天数）作为资源缺口程度的代理变量。该指标衡量的是资源消费强度而非严格意义上的缺口，存在两类偏差：（1）高活跃度玩家的消耗量天然偏高，即使缺口率不高；（2）囤积型玩家可能持有大量资源但消耗极少，被错误标记为低缺口。建议在问题 4 的数据采集中补充“当前升级目标所需资源量”和“资源消耗目的标签”，以实现精确的缺口率计算。

1.5 附录 E：AI 工具使用说明

本文在建模与论文撰写过程中使用了以下人工智能工具：DeepSeek

1.5.1 使用 1

人工智能工具名称：DeepSeek

输入的问题指令：Cox 预测模型是什么？

人工智能的输出结果：Cox 预测模型（Cox 比例风险回归模型）是生存分析的核心工具，用于分析“事件发生时间”数据（如患者死亡、疾病复发）。它同时评估多个因素对风险的影响，并输出个体化的生存预测。

核心特点：比例风险假设（不同个体的风险比值不随时间改变）；半参数模型（不假定风险函数的具体形状，灵活稳健）。

模型形式： $h(t)=h(t_0)\times\exp(\beta_1X_1+\cdots+\beta_kX_k)$ ， $\exp(\cdot)$ 为风险比，解释因素对风险的倍数影响。

预测应用：计算特定时间点的生存概率、风险分层（高/中/低风险组）、绘制列线图辅助临床决策。

常见领域：医学预后分析、流行病学、工程可靠性。需注意验证比例风险假设及变量线性关系。

1.5.2 使用 2

人工智能工具名称：DeepSeek

输入的问题指令：帮我搜索游戏付费策略有哪些相关论文？

人工智能的输出结果：以下是关于游戏付费策略相关论文列表：

- 主题：定价策略；论文：Pricing and Design of Pay-to-Win Add-Ons [2025]；核心发现：分析了付费致胜（Pay-to-Win）附加内容的定价与设计策略，研究其如何影响基础游戏及开发者的利润；来源：Management Science。

- 主题：定价策略；论文：Player-vs.-Player Game Design and Pricing [2024]；核心发现：为玩家对战（PvP）游戏开发了一个分析模型，研究在免费与付费版本共存的竞争性环境下，如何实现最优的版本划分与定价策略；来源：Information Systems Research。

- 主题：定价策略；论文：Determining the Pricing Strategy and Pricing the Products of Mobile Games；核心发现：为手游企业提出了一个系统性定价决策支持模型，采用两阶段决策过程来决定对哪些产品进行定价以及如何定价；来源：Mathematical Model Approach。

- 主题：付费机制；论文：Monetization mechanisms in gacha games: The behavioral triad of pricing strategies, pity systems, and belief of luck [2025]；核心发现：基于“定价策略、保底系统和运气信念”的行为三要素，探讨抽卡游戏的付费机制，发现高价会降低支付意愿，而保底机制能提升意愿；来源：ScienceDirect。

- 主题：付费机制；论文：Personalized game design for improved user retention and monetization in freemium games [2025]；核心发现：通过大规模随机对照实验，证明了在免费增值游戏中动态调整游戏难度，是一种能有效提升玩家留存与付费转化的个性化设计策略；来源：ScienceDirect。

- 主题：付费机制；论文：Two faces of freemium strategy in social games [2025]；核心发现：基于 S-O-R（刺激-有机体-反应）理论框架，研究在社交游戏中，免费策略如何通过感知享受和嫉妒等心理因素影响玩家的应用内购买意愿；来源：Journal of Retailing and Consumer Services。

- 主题：玩家心理；论文：The antecedents of players' financial commitment to make microtransactions in free-to-play games [2025]；核心发现：从感知易用性、态度、满意度和动机四个维度出发，构建了预测免费游戏玩家微交易付费意愿的前因模型；来源：Future Business Journal。

- 主题：玩家心理；论文：The influence of perceived aggressive monetization on mobile

gamers' in-app purchase behavior [2025]; 核心发现: 探讨了手游中“感知激进变现”如何与自控力、过往冲动消费共同影响玩家的付费行为; 来源: Universitas Kristen Satya Wacana。

- 主题: 玩家心理; 论文: Learning User Play-then-Pay Behaviors in Digital Games: A Dynamic Perspective [2025]; 核心发现: 从动态视角出发, 尝试构建模型来理解和学习用户在数字游戏中的“先玩后付”行为模式; 来源: City University of Hong Kong。

- 主题: 市场分析; 论文: An Exploratory Study of Video Game Pricing in the Southeast Asian Market [2025]; 核心发现: 聚焦东南亚市场, 通过 405 份问卷调查, 探索该地区玩家对游戏定价的看法和接受度, 填补了消费者行为研究的空白; 来源: Ejournals, Universitas Muhammadiyah Malang。

- 主题: 市场分析; 论文: Theseus: Understanding consumer behavior in in-app purchases for mobile games [2025]; 核心发现: 综合探讨了移动游戏内购的消费者行为, 分析了价值感知、心理因素和人口统计学特征对玩家消费模式的影响; 来源: Theseus。

1.5.3 使用 3

人工智能工具名称: DeepSeek

输入的问题指令: 帮我解析数据有哪些重要信息?

人工智能的输出结果: 其输出的要点包括: (1) pickdata2 为行为事件记录, register_time 可用于确定每名玩家的 Day1 时间基准, 需处理缺失值; (2) pickdata1 为资源变更记录, change_type 字段区分获取 (get) 与消耗 (reduce), 需按资源名和用户分组聚合; (3) total_pay 以美元标价, 0.99 USD 对应标准 6 元首充档, 论文中需统一换算为人民币; (4) 连续 2 天无 pickdata2 记录可作为行为流失的判定标准; (5) 需注意 193 万行和 416 万行的大数据量, 建议采用分块读取策略。

1.5.4 使用 4

人工智能工具名称: DeepSeek

输入的问题指令: 介绍一下 XGBoost

人工智能的输出结果: XGBoost 在二分类任务中表现很出色。简单来说, 它相当于用数百棵决策树组成的“精英团队”, 共同判断一个结果属于“是”或“否”, 整个过程就像一个持续进化的专家诊断系统。

核心原理与关键参数:

模型训练: 通过串行方式构建数百棵决策树, 每棵新树都专注于修正前一阶段的预测错误, 最终将所有树的预测结果累加得出最终预测。

非线性拟合: 与传统的逻辑回归不同, XGBoost 通过决策树的组合, 能自动捕捉数据中复杂的非线性关系。

目标函数: 在二分类任务中, 模型的目标函数为 binary:logistic。这与逻辑回归类似, 最终输出一个介于 0 和 1 之间的概率值, 代表了样本属于正类的可能性。

在建模时, 几个核心参数至关重要:

核心目标: 必须设置 objective='binary:logistic'。

性能监控: 通过 $eval_metric$ $logloss$ $error$ auc AUC

模型复杂度: 通过调整树的个数 $n_estimators$ max_depth $learning_rate$

处理数据不平衡：当正负样本比例悬殊时，可设置 $\text{scale}_{pos_weight}$